

PYTHON

SERIES DE TIEMPO

MACHINE LEARNING

Análisis y Pronóstico de Ventas en Retail

Caso práctico de portafolio orientado a análisis de datos, forecasting, insights de negocio y apoyo a decisiones comerciales.

Juan Camilo Jaramillo G.

Economista | Finanzas | Análisis de Datos | Excel | Power BI | Python

El documento resume un proyecto completo: integración de datos, limpieza, visualización, modelos predictivos e interpretación gerencial.



Evolución de ventas semanales

1. Datos analizados y objetivo del proyecto

El proyecto utiliza datos históricos de ventas semanales de Walmart. La información se encuentra a nivel de tienda y departamento, y se complementa con variables comerciales, económicas y características propias de cada establecimiento.

BASE 1

Train

Ventas semanales por tienda, departamento y fecha. Incluye la variable objetivo: Weekly_Sales.

BASE 2

Features

Variables externas: temperatura, combustible, CPI, desempleo, promociones y semanas festivas.

BASE 3

Stores

Información de las tiendas: tipo de establecimiento y tamaño, variables clave para explicar ventas.

Pregunta de negocio

- ¿Cómo se comportan las ventas en el tiempo?
- ¿Qué tiendas y departamentos concentran mayor volumen?
- ¿Qué papel tienen los festivos, promociones y tamaño de tienda?
- ¿Qué modelos pueden apoyar el pronóstico de demanda?

Objetivo

Analizar el comportamiento de las ventas e identificar patrones relevantes para apoyar decisiones de inventario, planificación comercial, desempeño por tienda/departamento y modelos de pronóstico.

Resultado esperado: convertir datos históricos en información clara, visual y accionable para el negocio.

2. Metodología aplicada

El proyecto se desarrolló siguiendo un flujo de trabajo analítico completo, desde la preparación de datos hasta la interpretación de resultados.



Tratamiento de datos

Se integraron las tres fuentes principales para obtener una tabla única de análisis.

Las columnas Markdown1 a Markdown5 fueron interpretadas como promociones o descuentos.

Los valores faltantes en Markdown fueron rellenados con cero, asumiendo ausencia de promoción.

Se crearon variables temporales como año, mes y semana para el modelo de ML.

Variables utilizadas

Objetivo: Weekly_Sales.

Identificación: Store, Dept.


Tiempo: Date, IsHoliday, Week, Month, Year.

Negocio: Type, Size, Markdown1-MarkDown5.


Entorno: Temperature, Fuel_Price, CPI, Unemployment.

3. Hallazgos del análisis exploratorio


El análisis exploratorio permitió identificar concentración de ventas, diferencias por formato de tienda, efecto de semanas festivas y patrones temporales clave.



Top 10 tiendas por ventas




Top 10 departamentos



Ventas por tipo de tienda


Conclusiones del EDA

Un grupo reducido de tiendas concentra una proporción relevante de las ventas totales.
 Algunos departamentos tienen un peso mucho mayor en el volumen comercial.
 Las tiendas tipo A muestran mayores ventas promedio que los formatos B y C.
 Las semanas festivas presentan ventas promedio superiores a las semanas normales.



Festivos vs no festivos

4. Tendencia temporal y correlación




Evolución de ventas en el tiempo

Lectura temporal

La serie muestra picos fuertes en periodos específicos del año.

Existen patrones estacionales que justifican un enfoque de series de tiempo.

La agregación semanal ayuda a observar el comportamiento general de la demanda.



Matriz de correlación

Conclusiones de correlación

Weekly_Sales no depende linealmente de una única variable explicativa.

Size presenta una asociación positiva relevante con las ventas.

Las variables Markdown muestran relaciones entre sí, lo que sugiere campañas combinadas.

El comportamiento de ventas es multifactorial: tiempo, tienda, departamento y negocio.

5. Enfoque de modelado

Se aplicaron dos modelos complementarios: SARIMA para ventas agregadas y Random Forest para observaciones tienda-departamento-semana.

Modelo 1: SARIMA

Aplicado sobre ventas semanales agregadas por fecha.

Busca capturar tendencia y estacionalidad.

Útil para entender el comportamiento general de la demanda.

No distingue diferencias internas entre tiendas y departamentos.

Modelo 2: Random Forest

Aplicado a nivel tienda, departamento y semana.

Incorpora variables comerciales, económicas, temporales y de tienda.


Permite capturar relaciones no lineales.

Aporta interpretación mediante importancia de variables.


Nota metodológica importante

Las métricas de SARIMA y Random Forest no son directamente comparables: SARIMA trabaja con ventas agregadas por semana, mientras que Random Forest predice observaciones a nivel de tienda-departamento-semana. Cada modelo responde a una perspectiva diferente del problema.

6. Resultados de los modelos



Pronóstico SARIMA



Importancia de variables - Random Forest

3.68%

SARIMA MAPE

Error porcentual promedio sobre ventas agregadas.

1.70M

SARIMA MAE

Error absoluto sobre ventas semanales agregadas.

2,191.54

RF MAE

Error promedio por observación tienda-departamento-semana.

2,212.10

RF WMAE

Métrica ponderada para semanas festivas.

Interpretación

SARIMA logró una aproximación adecuada del comportamiento agregado de ventas. Random Forest permitió identificar factores clave como Dept, Size, Store y Week, mostrando que las ventas dependen tanto de la estructura del negocio como del componente temporal.

7. Conclusiones y valor para clientes

Conclusión general

El proyecto permitió analizar ventas semanales de Walmart integrando información de tiendas, departamentos, fechas, festivos, promociones y variables económicas. El resultado muestra que las ventas no dependen de un solo factor: el comportamiento comercial se explica mejor al combinar análisis exploratorio, lectura temporal y modelos predictivos.

Conclusiones del análisis

Ventas por tienda:

Las tiendas 20, 4, 14, 13 y 2 concentran los mayores niveles de venta, lo que sugiere diferencias relevantes en demanda, tamaño o ubicación.

Festivos y estacionalidad:

Las semanas festivas muestran ventas promedio superiores y la serie temporal evidencia picos asociados a periodos comerciales clave.

Tipo de tienda y departamentos:

Las tiendas tipo A registran mayor venta promedio y algunos departamentos concentran gran parte de los ingresos.

Conclusiones de modelado

SARIMA:

El modelo de series de tiempo obtuvo un MAPE de 3.68% sobre ventas agregadas, mostrando buena aproximación para capturar tendencia y estacionalidad general.

Random Forest:

El modelo incorporó tienda, departamento, semana, promociones, festivos y variables económicas. Sus factores más relevantes fueron Dept, Size, Store y Week.

Lectura conjunta:

SARIMA explica la dinámica agregada; Random Forest permite entender diferencias operativas por tienda, departamento y semana.

Valor aplicado para clientes

Este tipo de solución puede apoyar decisiones de inventario, planeación de demanda, evaluación de promociones, seguimiento de desempeño comercial y construcción de reportes gerenciales o dashboards en Excel, Power BI o Python.